

Prognóstico de sobrevida em câncer de pulmão

Trabalho 1 — Inteligência Artificial II — 2026/02
Faculdade Antonio Meneghetti (AMF) — Sistemas de Informação
Tarefa de machine learning: classificação binária supervisionada

Resumo. Modelo de classificação que estima, no momento do diagnóstico, se um paciente com câncer de pulmão sobreviverá. O modelo final é uma Regressão Logística com regularização L1 ($C = 0,1$), com **ROC-AUC de 0,778** no conjunto de teste e 0,809 sob divisão temporal. O projeto dá peso central ao tratamento de vazamento de dados: três colunas pós-desfecho foram removidas antes de qualquer divisão, todo o pré-processamento vive dentro do Pipeline e o limiar de decisão é calibrado apenas no treino. A análise de ablação revela o achado mais relevante: **o estadiamento sozinho já alcança ROC-AUC 0,813, e as outras 37 variáveis agregam +0,0014** — menos de um terço do erro padrão da estimativa. O modelo é, na prática, um preditor de estágio, e o relatório discute por que esse resultado é honesto e o que ele diz sobre o dataset.

1. Dataset

Item	Descrição
Arquivo	lung_cancer_dataset.csv — incluído no repositório em data/raw/, sem qualquer modificação
Dimensões	2.000 registros x 46 colunas
Origem	Dataset público de registros oncológicos de câncer de pulmão, validado previamente com o professor
Unidade de análise	Um paciente diagnosticado com câncer de pulmão, identificado por Patient_ID
Cobertura	60 países agrupados em 6 regiões da OMS; diagnósticos entre 2015 e 2026
Variável alvo	Survived — binária (Yes / No)

1.1 Conteúdo das colunas

Grupo	N	Exemplos
Identificação e contexto	5	Patient_ID, Diagnosis_Year, Diagnosis_Date, WHO_Region, Country
Demografia	4	Age, Age_Group, Gender, BMI
Tabagismo	4	Smoking_Status, Cigarettes_Per_Day, Years_Smoking, Pack_Years
Exposições e fatores de risco	9	Asbestos_Exposure, Radon_Exposure, Air_Pollution_Exposure, Occupational_Hazard, Family_History
Sintomas	11	Coughing_Blood, Chest_Pain, Weight_Loss, Finger_Clubbing, Symptom_Count
Caracterização do tumor	6	Cancer_Type, NSCLC_Subtype, Cancer_Stage, Tumor_Size_cm, Metastasis, Genetic_Mutation
Diagnóstico e conduta	2	Diagnosis_Method, Treatment
Desfecho	2	Survival_Months, Survived

1.2 Justificativa de adequação ao problema

O dataset é adequado por quatro razões objetivas. Primeira: o alvo é binário, completo e razoavelmente equilibrado (62,2% / 37,8%), o que dispensa técnicas agressivas de reamostragem. Segunda: contém variáveis reconhecidamente prognósticas em oncologia torácica — estadiamento TNM, presença de metástase, tamanho do tumor, tipo histológico e carga tabágica —, o que permite confrontar o que o modelo aprende com o conhecimento clínico consolidado. Terceira: o volume de 2.000 registros é suficiente para uma divisão treino/teste honesta com validação cruzada, sem cair em estimativas instáveis. Quarta, e a mais relevante para este trabalho: o dataset contém variáveis registradas *depois* do desfecho, o que o torna um caso de estudo natural sobre vazamento de dados.

2. Problema e objetivo

2.1 Situação analisada

No atendimento oncológico, a estratificação de risco no momento do diagnóstico orienta decisões concretas: intensidade do acompanhamento, prioridade na fila cirúrgica, elegibilidade para protocolos experimentais e o teor da conversa com paciente e família. Essa estratificação hoje depende sobretudo do estadiamento e da experiência do oncologista. A pergunta do projeto é se um modelo estatístico, alimentado por variáveis rotineiramente disponíveis no diagnóstico, consegue apoiar essa decisão de forma reproduzível.

2.2 Objetivo

Estimar a probabilidade de sobrevida de um paciente **usando exclusivamente informação disponível no instante do diagnóstico**, e quantificar de forma honesta o quanto essa estimativa realmente vale.

A restrição temporal é a decisão de projeto mais importante. Ela define o que pode entrar no modelo. Um modelo que use o tempo de sobrevida ou o tratamento recebido pode exibir métricas excelentes e ser inútil na prática, porque essas informações não existem no momento em que a predição precisa ser feita. Toda a Seção 3.4 decorre dessa restrição.

2.3 Tipo de tarefa

Dimensão	Escolha
Tipo de aprendizado	Supervisionado
Tarefa	Classificação binária
Alvo	Survived : 1 = Yes (sobreviveu), 0 = No
Classe positiva	Yes — sobrevivência
Saída do modelo	Probabilidade contínua em [0,1], convertida em classe por um limiar calibrado
Métrica de seleção	ROC-AUC (independente de limiar e de prevalência)

3. Exploração e preparação dos dados

3.1 Qualidade dos dados

A qualidade do arquivo é atipicamente alta, o que por si só é um indício de origem sintética:

Verificação	Resultado	Consequência
Valores ausentes	0 em 92.000 células	Imputação mantida no pipeline por robustez, mas nunca acionada
Linhas duplicadas (ignorando o ID)	0	Nenhuma deduplicação necessária
Patient_ID único	2.000 / 2.000	Um registro por paciente; sem risco de agrupamento
Valores fora de faixa plausível	0	Nenhuma correção de domínio necessária
Coerência clínica interna	100%	Ver regras R7 na Seção 9




Figura 1 — Distribuição do alvo, mapa de ausentes e taxa de sobrevivência por ano. O desbalanceamento é leve (1,65:1). A taxa de sobrevivência não apresenta tendência temporal consistente, o que já sugere que o ano de diagnóstico carrega pouco sinal.

3.2 Distribuições e outliers

A idade concentra-se entre 50 e 79 anos (mediana 60), compatível com a epidemiologia da doença. O tamanho do tumor tem mediana de 4,3 cm e máximo de 13,3 cm. Aplicando o critério IQR de 1,5×, apenas Pack_Years apresenta contagem expressiva de pontos extremos:

Variável	Outliers IQR	%	Mín	Máx	Interpretação
Age	4	0,20	30	89	plausível
BMI	6	0,30	16,0	40,0	plausível
Tumor_Size_cm	8	0,40	0,5	13,3	plausível
Pack_Years	236	11,80	0,0	106,0	artefato de distribuição, não erro
Cigarettes_Per_Day	59	2,95	0	56	idem
Years_Smoking	32	1,60	0	59	idem

Por que nenhum outlier foi removido. Os 236 "outliers" de Pack_Years não são erros de medição. Como 65,6% dos pacientes nunca fumaram, o primeiro, o segundo e o terceiro quartis dessa variável são todos iguais a zero, o que zera o intervalo interquartil e faz o critério IQR classificar *qualquer* fumante como ponto extremo. A distribuição é inflada em zero, não contaminada. Remover esses registros eliminaria justamente os fumantes — o grupo de maior interesse clínico. Todos os 2.000 registros foram mantidos.




Figura 2 — Boxplots das variáveis numéricas. Note que as caixas de Pack_Years, Cigarettes_Per_Day e Years_Smoking estão colapsadas no zero: é a assinatura visual da inflação em zero descrita acima.




Figura 3 — Distribuições numéricas separadas por classe. Apenas `Tumor_Size_cm` mostra separação visual clara entre sobreviventes e não sobreviventes. `Age`, `BMI` e `Risk_Factor_Count` praticamente se sobrepõem.

3.3 Associação das variáveis com o alvo

Medindo a associação das variáveis categóricas com o alvo pelo V de Cramér, o resultado é fortemente concentrado:

Variável	V de Cramér	Leitura
Cancer_Stage	0,538	associação forte; domina todas as demais
Metastasis	0,381	forte, mas quase redundante com o estágio
Diagnosis_Method	0,202	moderada; reflete detecção precoce
Smoking_Status	0,137	fraca
Genetic_Mutation	0,077	muito fraca
Chronic_Lung_Disease	0,068	muito fraca
Coughing_Blood	0,066	muito fraca
Air_Pollution_Exposure	0,062	muito fraca (e com sinal invertido — ver Seção 7.4)




Figura 4 — Taxa de sobrevida por categoria. O gradiente do estadiamento é acentuado: 69,8% no Estádio I contra 5,5% no Estádio IV. `LDCT Screening` associa-se a 59,7% de sobrevida contra 27,2% do `PET Scan`, refletindo que rastreio detecta doença precoce enquanto PET costuma investigar doença já avançada.

3.4 Vazamento de dados: identificação e remoção

Três colunas foram removidas antes de qualquer divisão dos dados, por representarem informação inexistente no instante da predição.

Coluna	Tipo de vazamento	Evidência e justificativa
Survival_Months	Vazamento de alvo	É o próprio desfecho expresso em outra escala. AUC univariada de 0,778 — sozinha, quase iguala o modelo completo. Só existe depois que o desfecho ocorreu.
Treatment	Vazamento temporal	Decisão clínica posterior ao diagnóstico. A categoria Palliative Care (13,7% de sobrevida) codifica diretamente o prognóstico atribuído pelo médico — o modelo estaria copiando o julgamento humano, não prevenindo o desfecho.
Patient_ID, Diagnosis_Date	Identificadores	Sem conteúdo preditivo; risco de memorização. Diagnosis_Date é usada apenas para construir a divisão temporal de robustez.

Prova de que Survival_Months não é observável no diagnóstico. Cruzando o tempo de sobrevida com o ano de diagnóstico, **437 pacientes (21,9%) apresentam sobrevida maior que o seguimento fisicamente possível** — há registros de diagnóstico em 2026 com mais de 100 meses de sobrevida acumulada. É impossível por construção do calendário. A coluna é um valor atribuído após o desfecho, não uma medição disponível na data do diagnóstico. O painel central da Figura 5 mostra em vermelho todos os casos que violam essa fronteira.




Figura 5 — Evidência de vazamento. À esquerda, a separação que Survival_Months produz entre as classes. Ao centro, a incoerência temporal: a linha preta marca o seguimento máximo possível e os pontos vermelhos são os 437 casos impossíveis. À direita, o gradiente de sobrevida por tratamento, que revela Treatment como proxy do prognóstico médico.

3.5 Redundâncias determinísticas

A EDA identificou colunas que são função exata de outras. Todas foram confirmadas por teste automatizado (regras R9, Seção 9) e valem em 100% dos registros:

Coluna derivada	Fórmula exata verificada	Decisão
Pack_Years	Cigarettes_Per_Day / 20 × Years_Smoking	mantida
Symptom_Count	soma dos 10 sintomas binários	mantida
Risk_Factor_Count	soma dos 7 fatores de risco + indicador de poluição alta	mantida
Age_Group	discretização exata de Age em faixas decenais	removida
BMI_Category	discretização exata de BMI nos cortes da OMS	removida

O critério de decisão foi a perda de informação. Age_Group e BMI_Category são discretizações estritamente lossy de variáveis contínuas já presentes: não acrescentam nada e apenas degradam a resolução, por isso saíram. Os três agregados foram mantidos porque comprimem informação de forma útil a modelos de árvore, que não conseguem somar colunas sozinhos. A colinearidade que introduzem em modelos lineares é tratada pela regularização L1, que elimina o que for redundante.

Duas outras redundâncias foram documentadas mas não exigiram remoção, por serem implicações lógicas e não identidades: Stage IV → Metastasis = Yes (476 de 476 casos) e SCLC → NSCLC_Subtype = 'Not Applicable' (229 de 229). Country foi removida por cardinalidade: 60 níveis, com categorias de apenas 5 observações, o que produziria colunas dummy quase vazias; WHO_Region preserva o sinal geográfico com 6 níveis estáveis.




Figura 6 — Correlação de Spearman entre variáveis numéricas e o alvo. O bloco de correlação perfeita entre `Cigarettes_Per_Day`, `Years_Smoking` e `Pack_Years` é a assinatura da derivação determinística descrita acima.

3.6 Transformações aplicadas

Todas as transformações estão declaradas em `src/features.py` como um `ColumnTransformer` que vive dentro do `Pipeline` :

Grupo	N	Transformação	Justificativa
Numéricas	9	imputação por mediana → <code>StandardScaler</code>	Regressão Logística exige escalas comparáveis para que a penalização L1 atue de forma uniforme entre as variáveis
Binárias	18	<code>OrdinalEncoder</code> com categorias fixas [No, Yes]	Fixar as categorias impede que a codificação mude entre folds conforme os níveis presentes
Ordinais	5	<code>OrdinalEncoder</code> com ordem clínica explícita → escalonamento	<code>Cancer_Stage</code> (I<II<III<IV), exposição, consumo de álcool, exercício e tabagismo têm ordem real; codificá-las como nominais descartaria essa estrutura
Nominais	6	<code>OneHotEncoder</code> com <code>min_frequency=10</code>	Agrupa níveis raros em uma categoria única, evitando colunas quase vazias que induzem sobreajuste

Resultado: 38 colunas de entrada geram 63 atributos após a transformação. O parâmetro `remainder="drop"` funciona como camada extra de segurança — qualquer coluna não declarada explicitamente é descartada, de modo que uma coluna com vazamento que escapasse da política de exclusão ainda assim não chegaria ao modelo.

4. Estratégia experimental

4.1 Divisão dos dados

A divisão é **hold-out estratificado 80/20**, complementado por validação cruzada dentro do treino:

Conjunto	N	% positivos	Papel
Treino	1.600	37,8%	Triagem de candidatos, ajuste de hiperparâmetros, calibração do limiar
Teste (hold-out)	400	37,8%	Estimativa final, usada uma única vez

Dentro do treino, a validação cruzada faz o papel do conjunto de validação. Essa escolha foi preferida a um *split* treino/validação/teste em três partes porque, com 2.000 registros, reservar uma terceira partição deixaria cada conjunto pequeno demais e as estimativas instáveis. A validação cruzada usa todo o treino em rotação, entregando estimativas de menor variância com o mesmo volume de dados.

4.2 Validação cruzada: por que repetida

Erro cometido e corrigido no desenvolvimento. A primeira versão deste projeto usou `StratifiedKFold` de 5 folds para escolher hiperparâmetros. O desvio-padrão entre folds era de $\pm 0,034$, enquanto as diferenças entre configurações de `C` ficavam em torno de 0,003 — uma ordem de grandeza menor. Nessas condições, `GridSearchCV` escolhe pelo máximo numérico de uma estimativa dominada por ruído. O resultado foi a seleção de `C = 0,03`, que **zera 61 dos 63 coeficientes** e reduz o modelo a uma única variável, sem que isso representasse ganho real de desempenho.

A correção foi adotar `RepeatedStratifiedKFold`. Repetir a validação cruzada com diferentes particionamentos reduz o erro padrão da estimativa pela raiz do número de repetições:

Etap	Esquema	Estimativas	Erro padrão	Uso
Triagem	5 folds simples	5	~0,015	Descartar candidatos claramente inferiores
Ajuste de hiperparâmetros	5 × 3 repetições	15	~0,009	Escolher configuração dentro de cada família
Comparação final	5 × 5 repetições	25	~0,005	Escolher a família vencedora

4.3 Regra de decisão para a escolha do modelo

A escolha final não é feita pelo simples máximo. Reporta-se a média e o erro padrão de cada candidato, e modelos cuja média esteja dentro de um erro padrão do melhor são tratados como **empate técnico** — a diferença entre eles é ruído da estimativa, não evidência de superioridade. Entre os empatados, escolhe-se o de maior média.

4.4 Protocolo anti-vazamento

Seis medidas concretas garantem que a estimativa de desempenho seja honesta:

- Colunas pós-desfecho removidas antes da divisão.** A exclusão acontece em `src/data.py`, antes de qualquer *split*, para que nenhuma etapa posterior possa reintroduzi-las.
- Divisão antes de qualquer ajuste.** Nenhuma estatística é calculada sobre o dataset completo.
- Pré-processamento dentro do Pipeline.** Médias, desvios, medianas e vocabulários de categorias são aprendidos apenas nos folds de treino e aplicados aos demais. Este é o ponto onde a maior parte dos projetos de ML vaza sem perceber.
- Seleção de modelo e ajuste usam só o treino.** O teste não participa de nenhuma decisão.
- Limiar calibrado por `cross_val_predict` no treino.** O limiar é um hiperparâmetro; escolhê-lo olhando o teste seria vazamento.
- Teste tocado uma única vez.** Apenas ao final, para reportar.

4.5 Teste de robustez temporal

Como verificação adicional, o experimento foi repetido com divisão por ano de diagnóstico — treino com registros anteriores a 2024 ($n = 1.387$) e teste com 2024 em diante ($n = 613$). Essa divisão simula o uso real do modelo: treinar com o histórico disponível e prever pacientes futuros. É mais pessimista que o hold-out aleatório sempre que existe deriva temporal.

5. Modelagem

5.1 Candidatos avaliados

Modelo	Justificativa da escolha
Baseline (classe majoritária)	Piso de referência. Qualquer modelo precisa superá-lo para justificar sua existência.
Árvore de Decisão	Interpretável e com controle direto de complexidade; útil para expor o efeito da profundidade sobre o sobreajuste.
Regressão Logística	Linear, produz probabilidades, coeficientes lidos como razão de chances. A penalização L1 lida com a colinearidade introduzida pelos agregados derivados.
Random Forest	<i>Bagging</i> : baixa variância, robusto, pouco sensível a hiperparâmetros.
Gradient Boosting (HistGB)	<i>Boosting</i> histogramado; referência em dados tabulares e candidato natural a vencer.

5.2 Triagem com hiperparâmetros padrão

Modelo	ROC-AUC CV	ROC-AUC treino	Gap	F1 CV
Regressão Logística	0,8017 ± 0,0322	0,8371	+0,035	0,692
Random Forest	0,7952 ± 0,0217	1,0000	+0,205	0,625
Gradient Boosting (HistGB)	0,7902 ± 0,0279	0,9671	+0,177	0,675
Árvore de Decisão	0,6390 ± 0,0158	1,0000	+0,361	0,551
Baseline	0,5000	0,5000	0,000	0,000

Os três modelos de árvore memorizam o treino sem hiperparâmetros de controle: Random Forest e Árvore de Decisão atingem ROC-AUC 1,000 no treino contra 0,795 e 0,639 em validação. A Regressão Logística já parte com gap de apenas 0,035, o que antecipa o resultado final.

5.3 Ajuste de hiperparâmetros

Modelo	Espaço	Estratégia	Melhor configuração
Árvore de Decisão	60	Randomized, 12 amostras	criterion=entropy, max_depth=3, min_samples_leaf=20
Regressão Logística	14	Grid exaustivo	C=0.1, penalty=l1
Random Forest	8	Grid exaustivo	n_estimators=300, max_depth=6, max_features=0.4, min_samples_leaf=15
Gradient Boosting	54	Randomized, 12 amostras	learning_rate=0.03, max_leaf_nodes=15, min_samples_leaf=40, l2=0.0, max_iter=300

Todos os candidatos foram ajustados, e não apenas o vencedor da triagem: a ordem com hiperparâmetros padrão pode se inverter depois do ajuste. A Árvore de Decisão é o exemplo — saltou de 0,639 para 0,808 quando a profundidade foi limitada a 3.

5.4 Comparação final e modelo escolhido

Modelo	ROC-AUC (CV 5×5)	Erro padrão	Situação
Regressão Logística	0,8144	0,0050	escolhido
Random Forest	0,8094	0,0043	empate técnico
Árvore de Decisão	0,8079	0,0043	fora de 1 EP
Gradient Boosting (HistGB)	0,8002	0,0044	fora de 1 EP

A Regressão Logística vence, mas a leitura correta é que **as quatro famílias convergem para a mesma faixa de 0,80 a 0,81**. Quando modelos com capacidades tão diferentes — de uma árvore de profundidade 3 a um *ensemble* de 300 árvores — chegam ao mesmo desempenho, o limitante não é o algoritmo: é a quantidade de informação disponível nos dados. A Seção 7.2 quantifica isso.

5.5 Configuração do modelo final

Componente	Configuração
Algoritmo	LogisticRegression (scikit-learn 1.8.0)
Regularização	L1 (Lasso), C = 0,1 — equivale a λ = 10
Solver	liblinear (necessário para L1 em problema binário)
Desbalanceamento	class_weight='balanced' — pondera as classes pelo inverso da frequência
Limiar de decisão	0,464, calibrado por cross_val_predict no treino para maximizar F1
Atributos ativos	8 de 63 (a penalização L1 zerou 55)
Semente	random_state = 42 em toda divisão e estimador

Sobre o tratamento do desbalanceamento: com razão de 1,65:1, optou-se por class_weight='balanced' em vez de sobreamostragem sintética do tipo SMOTE. A ponderação por classe atinge o mesmo objetivo sem fabricar registros de pacientes inexistentes e sem o risco de vazamento que a reamostragem introduz quando aplicada fora do pipeline de validação cruzada.

6. Avaliação

6.1 Métricas escolhidas e por quê

Métrica	Papel no problema
ROC-AUC	Métrica de seleção. Independe do limiar e da prevalência; mede a capacidade de ordenar pacientes por risco, que é o uso clínico pretendido.
PR-AUC	Mais sensível ao desempenho na classe minoritária (sobreviventes, 37,8%).
Revocação	Fração de sobreviventes corretamente identificados. Alta revocação evita subestimar a chance de um paciente e negar-lhe tratamento agressivo.
F1	Equilíbrio entre precisão e revocação; usado para calibrar o limiar.
Acurácia balanceada	Média das revocações das duas classes; não é inflada pela classe majoritária.
MCC	Coefficiente de correlação de Matthews; robusto a desbalanceamento, usa as quatro células da matriz de confusão.
Brier	Erro quadrático das probabilidades; avalia calibração, não apenas ordenação.

6.2 Resultados

Conjunto	ROC-AUC	PR-AUC	Acurácia	Acur. bal.	Precisão	Revocação	F1	MCC	Brier
Treino (reajuste)	0,8263	0,6970	0,7475	0,7704	0,6189	0,8645	0,7214	0,5254	0,1707
Validação cruzada (OOF)	0,8126	0,6582	0,7475	0,7704	0,6189	0,8645	0,7214	0,5254	0,1738
Teste (hold-out)	0,7783	0,6308	0,7075	0,7325	0,5780	0,8344	0,6829	0,4526	0,1951
Teste temporal (≥ 2024)	0,8091	0,6840	0,7390	0,7603	0,6205	0,8583	0,7203	0,5099	0,1776

O modelo supera com folga o baseline: **ROC-AUC 0,778 contra 0,500**, e acurácia balanceada 0,732 contra 0,500. A divisão temporal — mais exigente por construção — entrega **0,809**, acima do hold-out aleatório, o que indica ausência de deriva temporal prejudicial e reforça a estabilidade da estimativa.

6.3 Matriz de confusão e curvas

Teste (n = 400, limiar 0,464)	Previsto: não sobrevive	Previsto: sobrevive
Real: não sobreviveu (249)	157 (VN)	92 (FP)
Real: sobreviveu (151)	25 (FN)	126 (VP)

O perfil de erro é assimétrico por escolha deliberada: 92 falsos positivos contra apenas 25 falsos negativos. O limiar calibrado privilegia revocação (0,834), de modo que o modelo raramente classifica como condenado um paciente que sobreviveria. Num contexto clínico de triagem, essa assimetria é a desejável — o custo de subestimar a chance de um paciente e negar-lhe tratamento agressivo é maior que o custo de um otimismo que será corrigido pelo acompanhamento.




Figura 7 — Matriz de confusão, curva ROC (AUC 0,778), curva precisão-revocação (AP 0,631 contra base de 0,378) e curva de calibração (Brier 0,195).




Figura 8 — À esquerda, métricas em função do limiar. A curva de F1 é achatada em torno do ótimo, indicando que a escolha do limiar não é frágil. À direita, a distribuição dos escores por classe no teste: há separação clara nos extremos e uma zona central de sobreposição, que corresponde aos estádios II e III.

7. Análise dos resultados

7.1 Underfitting e overfitting

Comparação	Gap de ROC-AUC	Leitura
Treino – Teste	+0,0480	Sobreajuste leve, dentro do esperado
Validação cruzada – Teste	+0,0344	Parte do gap vem da variabilidade amostral do hold-out, não de memorização
Treino – Validação cruzada	+0,0137	Sobreajuste real do modelo é muito pequeno

A curva de aprendizado confirma o diagnóstico. Com 128 amostras, o gap entre treino e validação é de 0,056; com 1.280, cai para 0,012 — o modelo converge em vez de divergir, assinatura de ausência de sobreajuste relevante. Ao mesmo tempo, a curva de validação **satura em torno de 0,817 já a partir de 292 amostras** e permanece plana até o fim.

Amostras de treino	ROC-AUC treino	ROC-AUC validação	Gap
128	0,8643	0,8087	0,0557
292	0,8608	0,8161	0,0447
621	0,8455	0,8159	0,0296
950	0,8383	0,8182	0,0200
1.280	0,8271	0,8154	0,0117

Conclusão do diagnóstico. O modelo não está sobreajustado nem subajustado: está no teto do que estes dados permitem. Coletar mais pacientes com as mesmas variáveis não melhoraria o resultado — a curva de validação já é plana. Melhorar exigiria outras variáveis, não mais registros.




Figura 9 — Curva de aprendizado. As duas curvas convergem e a de validação satura, o que caracteriza um modelo limitado pela informação disponível nos dados, e não pela capacidade do algoritmo.

7.2 O achado central: o modelo é um preditor de estágio

Para quantificar de onde vem o poder preditivo, partiu-se de um modelo com apenas `Cancer_Stage` e adicionaram-se blocos clínicos em ordem de disponibilidade, medindo o ganho com validação cruzada repetida 5×5:

Bloco acumulado	Variáveis	ROC-AUC	Ganho	Relevância
Estadiamento	1	0,8130 ± 0,0048	—	ponto de partida
+ Tumor e metástase	5	0,8109 ± 0,0048	−0,0020	dentro do ruído
+ Método de diagnóstico	6	0,8109 ± 0,0048	+0,0000	dentro do ruído
+ Demografia	10	0,8106 ± 0,0055	−0,0004	dentro do ruído
+ Tabagismo e estilo de vida	19	0,8159 ± 0,0050	+0,0053	marginal
+ Sintomas	30	0,8154 ± 0,0051	−0,0005	dentro do ruído
+ Genética e comorbidades	38	0,8144 ± 0,0050	−0,0010	dentro do ruído

O resultado mais importante do trabalho. Acrescentar **37 variáveis** ao estadiamento produz ganho total de **+0,0014 de ROC-AUC** — equivalente a **0,29 de um erro padrão** da própria estimativa. Estatisticamente, é indistinguível de zero. Como referência absoluta: ordenar os pacientes apenas pelo estágio, sem modelo algum, já entrega ROC-AUC de **0,806**.

Isso explica coerentemente três observações anteriores que, isoladas, pareciam desconexas: por que as quatro famílias de modelos convergem para a mesma faixa (Seção 5.4), por que a curva de validação satura com menos de 300 amostras (Seção 7.1) e por que a regularização L1 elimina 55 dos 63 atributos (Seção 7.3). As três são consequências de um mesmo fato — fora do estadiamento, o dataset contém pouquíssimo sinal.




Figura 10 — À esquerda, desempenho acumulado por bloco com barras de erro padrão; a linha vermelha marca o desempenho do estágio isolado, sem modelo. À direita, ganho marginal de cada bloco; barras cinzas indicam ganhos dentro do ruído da estimativa.

7.3 Interpretação com SHAP e importância por permutação

A penalização L1 manteve 8 dos 63 atributos. Os valores SHAP foram calculados com `LinearExplainer`, que é exato para modelos lineares — sem amostragem nem aproximação.

Atributo	Coefficiente	SHAP médio	Importância por permutação	Direção
Cancer_Stage	−1,3929	1,2940	+0,2577	estádio maior reduz a sobrevida
Coughing_Blood	−0,1377	0,0475	+0,0010	hemoptise reduz a sobrevida
Chest_Pain	−0,0570	0,0257	≈ 0	dor torácica reduz a sobrevida
Alcohol_Use	−0,0534	0,0452	≈ 0	consumo maior reduz a sobrevida
Gender_Male	−0,0344	0,0166	+0,0003	sexo masculino reduz a sobrevida
Fatigue	−0,0136	0,0059	≈ 0	fadiga reduz a sobrevida
Age	+0,0639	0,0547	+0,0008	idade maior aumenta a sobrevida (?)
Air_Pollution_Exposure	+0,1254	0,1033	+0,0046	poluição maior aumenta a sobrevida (?)

A concentração é extrema: o |SHAP| médio de `Cancer_Stage` é **12,5 vezes maior** que o do segundo colocado. Na importância por permutação, embaralhar o estadiamento derruba o ROC-AUC em 0,258, enquanto embaralhar qualquer outra variável produz queda inferior a 0,005 — dentro da própria incerteza da medida.

Os seis coeficientes negativos são clinicamente coerentes: estágio avançado, hemoptise, dor torácica, fadiga, consumo de álcool e sexo masculino são todos associados a pior prognóstico na literatura oncológica. A magnitude é pequena, mas a direção é a esperada.




Figura 11 — Beeswarm SHAP. Cada ponto é um paciente do conjunto de teste. A dispersão horizontal de `Cancer_Stage` domina o gráfico; as demais variáveis formam faixas estreitas em torno de zero.




Figura 12 — À esquerda, importância por permutação medida no teste. À direita, os 8 coeficientes não nulos da Regressão Logística sobre variáveis padronizadas.




Figura 13 — Explicação SHAP de dois casos individuais do teste: o paciente com maior e o com menor probabilidade prevista. Mostra como a contribuição de cada variável se soma para formar a decisão em um caso concreto.

7.4 Limitações identificadas

(a) Dois coeficientes têm sinal clinicamente implausível. Age e Air_Pollution_Exposure aparecem com coeficiente positivo: pelo modelo, ser mais velho e estar mais exposto à poluição *aumentam* a probabilidade de sobreviver. Isso contradiz o conhecimento oncológico estabelecido. A análise *what-if* torna o efeito visível — num paciente idêntico em tudo o mais, o modelo prevê 0,533 aos 40 anos e 0,595 aos 80. A EDA confirma que o padrão está nos dados (33,5% de sobrevida sob poluição baixa contra 41,2% sob poluição alta), o que caracteriza **artefato da geração sintética do dataset, não achado clínico**. O modelo está aprendendo corretamente uma relação que não existe no mundo real.

(b) As probabilidades não são bem calibradas. A curva de calibração (Figura 7, painel direito) fica sistematicamente abaixo da

diagonal: o modelo superestima a probabilidade de sobrevida. A causa é o `class_weight='balanced'`, que reequilibra as classes ao custo de distorcer as probabilidades absolutas. Isso é aceitável para ordenar pacientes por risco — o uso pretendido, medido por ROC-AUC —, mas inviabiliza ler a saída como probabilidade real. Corrigir exigiria `CalibratedClassifierCV` com *isotonic* ou *Platt scaling* aplicado sobre o treino.

(c) O dataset é sintético. Além da qualidade impossivelmente perfeita (zero ausentes, zero duplicatas, zero valores fora de faixa em 92.000 células), há a incoerência temporal de 437 registros documentada na Seção 3.4. Nenhuma conclusão clínica deve ser extraída deste trabalho; o valor está no método.

(d) O modelo não substitui o estadiamento. Dado o resultado da Seção 7.2, um oncologista que use apenas a tabela de estadiamento TNM obtém desempenho estatisticamente equivalente ao deste modelo. O sistema não agrega informação sobre a prática clínica atual neste dataset.

(e) Ausência de dados de seguimento longitudinal. A tarefa é tratada como classificação binária porque o dataset não permite outra coisa. O enquadramento correto para prognóstico oncológico seria **análise de sobrevivência** (Kaplan-Meier, Cox, Random Survival Forest), que trata censura à direita e prevê tempo até o evento em vez de um rótulo binário. A existência de `Survival_Months` no dataset sugere que esse seria o desenho natural — mas a coluna não é utilizável, pelas razões da Seção 3.4.

7.5 O que o experimento de vazamento revelou

Um experimento dedicado (`src/leakage_experiment.py`) mediu o impacto das variáveis removidas, com hiperparâmetros reajustados em cada configuração para que a comparação fosse justa:

Configuração	ROC-AUC CV	ROC-AUC teste	Δ vs. A
A. Sem vazamento (modelo entregue)	0,8161	0,7824	—
B. + <code>Treatment</code>	0,8161	0,7824	+0,0000
C. + <code>Survival_Months</code>	0,8139	0,7750	-0,0073
D. + ambas	0,8139	0,7751	-0,0073

Resultado contraintuitivo, e por que ele é honesto. As variáveis com vazamento **não inflaram** o desempenho. A explicação está na redundância: a correlação de Spearman entre `Survival_Months` e o estadiamento é de **-0,878**, e a mediana de sobrevida cai monotonicamente de 62 meses no Estádio I para 9 meses no Estádio IV. Como o estadiamento já está legitimamente disponível, as variáveis vazadas não trazem informação nova. A remoção continua obrigatória — no uso real elas simplesmente não existem no instante da predição —, mas neste dataset ela **não custa nada em desempenho**. Relatar isso, em vez de alegar uma inflação que não ocorreu, é parte da honestidade do trabalho.

Como o vazamento de variáveis não produziu efeito mensurável aqui, foi construída uma demonstração controlada do tipo de vazamento que *de fato* infla resultados — o de pré-processamento. Com 2.000 amostras, 3.000 atributos de ruído puro e rótulos aleatórios, o desempenho verdadeiro é 0,500 por construção:

Procedimento	ROC-AUC aparente no teste	Ilusão
Seleção de 20 atributos ajustada no dataset inteiro , depois dividida	0,6761	+0,176
Mesma seleção dentro do Pipeline , refeita a cada ajuste	0,4900	-0,010

Ajustar a seleção de atributos antes da divisão produz ROC-AUC aparente de 0,676 sobre dados que, por construção, não contêm sinal algum. É exatamente o erro que a arquitetura deste projeto impede: com o pré-processamento dentro do `Pipeline`, o mesmo procedimento devolve 0,490, corretamente próximo do acaso.




Figura 14 — Diagnóstico de vazamento. À esquerda e ao centro, a ablação das variáveis pós-desfecho. À direita, a demonstração controlada: a curva vermelha é a ilusão criada pelo vazamento de pré-processamento; a verde é o resultado correto.

8. Demonstração de funcionamento

O módulo `src/predict.py` carrega o modelo persistido em `models/model.joblib` e demonstra seu funcionamento em três formatos: predições sobre pacientes reais do conjunto de teste, três casos clínicos sintéticos construídos à mão e uma análise *what-if* variando uma única variável por vez. A execução completa está reproduzida abaixo.

8.1 Predições em pacientes reais do conjunto de teste

A amostra abaixo foi deliberadamente equilibrada entre acertos e erros, para não apresentar apenas os casos favoráveis. A acurácia sobre os 400 pacientes do teste é de 70,8%, e a distribuição de confiança das predições é de 226 de alta, 143 de média e 31 de baixa.

```
1. PREDICOES EM PACIENTES REAIS DO CONJUNTO DE TESTE
=====
Patient_ID Age Gender Cancer_Stage Metastasis Tumor_Size_cm prob_sobrevida predicao confianca real_acerto
LC-1852 81 Male Stage IV Yes 6.1 0.1218 Não sobrevive alta Não sobreviveu OK
LC-1227 69 Male Stage IV Yes 7.4 0.1050 Não sobrevive alta Não sobreviveu OK
LC-1599 70 Female Stage I No 1.0 0.8401 Sobrevive alta Sobreviveu OK
LC-0420 56 Female Stage I No 2.0 0.8499 Sobrevive alta Sobreviveu OK
LC-0575 63 Male Stage I No 0.5 0.8399 Sobrevive alta Sobreviveu OK
LC-1520 59 Female Stage IV Yes 7.7 0.0884 Não sobrevive alta Não sobreviveu OK
LC-0196 89 Male Stage III No 6.7 0.2765 Não sobrevive média Sobreviveu ERRO
LC-1623 71 Female Stage I No 1.3 0.8615 Sobrevive alta Não sobreviveu ERRO
LC-1879 61 Female Stage II No 3.1 0.6169 Sobrevive média Não sobreviveu ERRO
LC-1627 67 Male Stage I No 2.5 0.8106 Sobrevive alta Não sobreviveu ERRO
LC-0808 56 Male Stage I No 2.3 0.8279 Sobrevive alta Não sobreviveu ERRO
LC-1672 57 Male Stage I No 0.8 0.8340 Sobrevive alta Não sobreviveu ERRO

Acurácia no conjunto de teste completo (400 pacientes): 70.8%
Distribuição da confiança das predições:
confianca
alta 226
média 143
baixa 31
=====
```

8.2 Casos clínicos sintéticos e análise what-if

```
2. CASOS CLINICOS SINTETICOS
=====

Caso A – rastreio precoce, não fumante
estádio Stage I tumor 1.8 cm sintomas 1
probabilidade de sobrevida: 0.814 |#####|
predição: Sobrevive (confiança alta)

Caso B – doença avançada, tabagista pesado
estádio Stage IV tumor 8.5 cm sintomas 8
probabilidade de sobrevida: 0.100 |###|
predição: Não sobrevive (confiança alta)

Caso C – intermediário, quadro ambíguo
estádio Stage II tumor 4.2 cm sintomas 4
probabilidade de sobrevida: 0.566 |#####|
predição: Sobrevive (confiança média)

3. ANALISE WHAT-IF – VARIANDO UMA UNICA VARIÁVEL
=====

Efeito do estadiamento (demais variáveis fixas no Caso C):
Stage I prob = 0.817 |#####| -> Sobrevive
Stage II prob = 0.566 |#####| -> Sobrevive
Stage III prob = 0.276 |#####| -> Não sobrevive
Stage IV prob = 0.100 |###| -> Não sobrevive

Efeito da idade (Caso C, estágio II):
40 anos prob = 0.533
50 anos prob = 0.549
60 anos prob = 0.565
70 anos prob = 0.580
80 anos prob = 0.595

Efeito da hemoptise (Coughing Blood), Caso C:
Coughing_Blood = No prob = 0.566
Coughing_Blood = Yes prob = 0.532

Predições do teste exportadas -> artifacts/predicoes_teste.csv
```

Leitura da análise what-if. Mantendo todas as demais variáveis fixas no Caso C, mover o estadiamento de I para IV faz a probabilidade prevista cair de 0,817 para 0,100 — e inverte a decisão entre os estádios II e III. Nenhuma outra variável produz efeito comparável: variar a idade de 40 para 80 anos move a probabilidade de 0,533 para 0,595, e a presença de hemoptise a reduz de 0,566 para 0,532. É a confirmação prática, caso a caso, do que a Seção 7.2 mostrou de forma agregada.

8.3 Execução do harness de validação

Toda execução de treinamento é precedida pela validação automática do contrato de dados. Saída real do `src/validate.py`:

```
VALIDACAO DO DATASET BRUTO
[OK] R1 schema: 46 colunas esperadas presentes
[OK] R1 schema: colunas numéricas com dtype numérico
[OK] R2 alvo: sem valores ausentes
[OK] R2 alvo: níveis == {'Yes', 'No'}
[OK] R2 alvo: classe minoritária = 37.8% (> 5%)
[OK] R3 ausentes: 0 valores nulos no dataset
[OK] R4 duplicidade: Patient_ID único
[OK] R4 duplicidade: 0 linhas idênticas (sem ID)
...
[OK] R6 categorias: Swallowing_Difficulty binária Yes/No
[OK] R6 categorias: Finger_Clubbing binária Yes/No
[OK] R6 categorias: Metastasis binária Yes/No
[OK] R7 coerência: 'Never Smoked' => carga tabágica zero
[OK] R7 coerência: SCLC => NSCLC Subtype == 'Not Applicable'
[OK] R7 coerência: Stage IV => Metastasis == 'Yes'
[OK] R9 derivação: Pack_Years == Cigarettes_Per_Day/20 * Years_Smoking
[OK] R9 derivação: Symptom_Count == soma dos 10 sintomas
[OK] R9 derivação: Risk_Factor_Count == 7 fatores + poluição alta
```

Nota sobre a entrega. As saídas acima são as execuções reais dos módulos do repositório. Conforme exigido pelo enunciado, devem ser acompanhadas de **screenshots ou gravação de tela** capturados no ambiente do aluno, executando `bash run_all.sh` ou `python -m src.predict`.

9. Extensão opcional: estrutura do harness

O enunciado recomenda a elaboração de um *harness* — contexto, instruções, ferramentas, regras e validações que garantam comportamento consistente e verificável. Neste projeto o harness não é um agente de IA generativa, e sim uma **camada de contrato de dados executável**, implementada em `src/config.py` e `src/validate.py`. A escolha foi deliberada: o risco real do projeto não era a geração de texto, era o vazamento silencioso de dados.

9.1 Contexto e ferramentas

Componente	Arquivo	Responsabilidade
Contexto	<code>src/config.py</code>	Fonte única de verdade: schema esperado, definição do alvo, política de exclusão de colunas, faixas válidas, semente e parâmetros experimentais. Nenhum outro módulo redefine esses valores.
Regras e validações	<code>src/validate.py</code>	Nove grupos de regras executáveis que interrompem a execução ao primeiro desvio.
Ferramenta de dados	<code>src/data.py</code>	Ponto único de entrada para obter (X, y); aplica a exclusão de vazamento antes de qualquer divisão.
Ferramenta de transformação	<code>src/features.py</code>	<code>ColumnTransformer</code> com <code>remainder="drop"</code> , que descarta qualquer coluna não declarada.
Reprodutibilidade	<code>run_all.sh</code>	Executa o projeto inteiro na ordem correta, do zero.

9.2 Regras de validação

Regra	Categoria	Verificação
R1	Schema	As 46 colunas esperadas existem; numéricas têm dtype numérico
R2	Alvo	Binário, sem ausentes, com as duas classes presentes e minoritária acima de 5%
R3	Compleitude	Zero valores nulos nas colunas utilizadas
R4	Duplicidade	<code>Patient_ID</code> único; zero linhas idênticas ignorando o identificador
R5	Domínio	Nove variáveis numéricas dentro de faixas clinicamente plausíveis
R6	Vocabulário	Níveis categóricos observados pertencem ao conjunto esperado
R7	Coerência clínica	Não fumante $\implies$ carga tabágica zero; SCLC $\implies$ subtipo "Not Applicable"; Estádio IV $\implies$ metástase presente
R8	Anti-vazamento	Nenhuma coluna proibida sobrevive até a matriz de features; treino e teste sem interseção de índices nem de linhas
R9	Derivação	Agregados continuam sendo função exata das colunas de origem

A regra R8 é a mais importante do conjunto. Ela verifica explicitamente que nenhuma das colunas listadas em `DROP_ALWAYS` chegou à matriz de atributos, e que os conjuntos de treino e teste são disjuntos. Como a verificação é uma asserção que levanta exceção, é impossível treinar um modelo sobre dados que violem o contrato — a execução falha antes.

9.3 Reprodutibilidade

Mecanismo	Implementação
Semente fixa	<code>random_state = 42</code> em toda divisão, reamostragem e estimador
Ambiente declarado	<code>requirements.txt</code> com versões fixadas; a versão do scikit-learn é gravada dentro de <code>model.joblib</code>
Execução única	<code>bash run_all.sh</code> reproduz todas as figuras e métricas do zero
Artefatos persistidos	Métricas em JSON/CSV em <code>artifacts/</code> , permitindo conferência sem reexecutar
Checkpoint	A busca de hiperparâmetros grava <code>artifacts/searches.joblib</code> ; análises posteriores podem ser refeitas sem repetir a etapa cara

9.4 Estrutura do repositório

<code>data/raw/lung_cancer_dataset.csv</code>	dataset original, sem modificações
<code>src/</code>	
<code> config.py</code>	contexto: schema, política de exclusão, parâmetros
<code> validate.py</code>	harness: 9 grupos de regras que falham alto
<code> data.py</code>	carga, remoção de vazamento, divisões
<code> features.py</code>	<code>ColumnTransformer</code> (todo pré-processamento vive aqui)
<code> models.py</code>	5 candidatos + grades de busca
<code> evaluation.py</code>	métricas, calibração de limiar, relatórios
<code> train.py</code>	triagem, ajuste, limiar, avaliação final
<code> interpret.py</code>	curvas, importâncias, SHAP
<code> leakage_experiment.py</code>	ablação de vazamento + demonstração controlada
<code> ablation.py</code>	valor incremental por bloco de variáveis
<code> predict.py</code>	demonstração de funcionamento e what-if
<code>models/model.joblib</code>	pipeline treinado + limiar + metadados
<code>artifacts/</code>	métricas em JSON/CSV, predições, logs, checkpoint
<code>reports/</code>	
<code> relatorio.pdf</code>	este documento
<code> figures/</code>	14 figuras geradas pelo código
<code>requirements.txt</code>	
<code>run_all.sh</code>	
<code>README.md</code>	

10. Conclusão

O projeto entrega um classificador de sobrevida em câncer de pulmão com ROC-AUC de 0,778 no conjunto de teste e 0,809 sob divisão temporal, construído sob um protocolo anti-vazamento de seis camadas e validado por um harness de nove grupos de regras executáveis.

O resultado mais relevante, porém, é negativo — e é o que dá valor ao trabalho. A análise de ablação mostra que **o estadiamento sozinho alcança ROC-AUC de 0,813 e que as outras 37 variáveis agregam 0,29 de um erro padrão**. Quatro famílias de algoritmos com capacidades muito distintas convergem para a mesma faixa de desempenho; a curva de aprendizado satura com menos de 300 amostras; a regularização L1 descarta 55 de 63 atributos. As três observações têm a mesma causa: fora do estadiamento, este dataset contém pouquíssima informação.

Um modelo que apresentasse apenas o ROC-AUC de 0,778 pareceria um sucesso modesto. A ablação mostra que ele é, na prática, equivalente a consultar a tabela de estadiamento TNM. Chegar a essa conclusão exigiu justamente o rigor metodológico descrito nas Seções 4 e 7 — e ela teria passado despercebida sob um protocolo menos cuidadoso.

Três lições metodológicas registradas neste trabalho:

1. **Vazamento nem sempre infla o resultado.** As variáveis pós-desfecho aqui eram redundantes com o estadiamento e sua remoção não custou desempenho. A remoção continua obrigatória por método, não por métrica.
2. **Selecionar hiperparâmetros com CV ruidosa é sorteio.** Com 5 folds, o desvio entre folds superava em dez vezes a diferença entre configurações, e a escolha resultante colapsou o modelo a uma única variável. A validação cruzada repetida corrigiu o problema.
3. **Desempenho absoluto não diz se o modelo é útil.** Só a comparação contra uma referência simples — neste caso, o próprio estadiamento — revela quanto o modelo realmente agrega.

Relatório gerado a partir dos artefatos em `artifacts/` e das figuras em `reports/figures/`, todos produzidos pelo código do repositório. Reprodução completa: `bash run_all.sh`.